

Часть А

Вопросы:

1. У какого файла, по вашему ожиданию, будет самая высокая RMS-энергия?

Я ожидала, что самая высокая RMS энергия будет у `clipped_speech_like.wav`, так как амплитуда этого сигнала выше, чем записывающее устройство может зафиксировать. Однако, как показывает Таблица 1, самая высокая RMS энергия у `noisy_speech_like.wav`. Скорее всего это потому, что шум широкополосный и он полностью исключает тишину, сигнал «заполняет» энергией на всем протяжении. А клипированный сигнал имеет высокую энергию только в некоторых промежутках (которые обрезаны).

2. В каком файле, по вашему ожиданию, искажение волновой формы будет наиболее заметным?

Я ожидала, что самое сильное искажение будет у `noisy_speech_like.wav`, так как шум будет иметь более-менее случайный характер, а потому повлияет на форму волны значительно, на всех частотах и во все моменты времени.

3. В каком файле, по вашему ожиданию, спектральные переходы будут наиболее размытыми?

Я ожидаю, что спектральные переходы будут наиболее размытыми у `noisy_speech_like.wav`, так как шум будет «подмешивать» в сигнал разные частоты.

Часть В

Таблица 1. Статистика аудио

filename	sample_rate_hz	duration_s	num_samples	peak_amplitude	rms	silence_fraction	clipping_fraction
clean_speech_like.wav	16000	5.2	83200	0.780029	0.250151	0.38893	2.4e-05
clipped_speech_like.wav	16000	5.2	83200	0.340027	0.245213	0.29869	0.463798
noisy_speech_like.wav	16000	5.2	83200	0.920013	0.265441	0.0772	1.2e-05
reverberant_speech_like.wav	16000	5.2	83200	0.880005	0.216411	0.385096	0.000108
speed_perturbed_speech_like.wav	16000	4.522	72348	0.780029	0.250186	0.389244	1.4e-05

Вопросы:

1. У какого файла доля клиппинга ненулевая или необычно высокая? Почему?

У файла `clipped_speech_like.wav` доля клиппинга самая большая (46%), так как в нем содержится клиппированный сигнал, то есть, сигнал с такой высокой амплитудой, что ее истинные значения невозможно было записать, и устройство обрезало эту амплитуду. Амплитуда остальных записей находится в пределах динамического диапазона записывающего устройства, поэтому доля клиппированного сигнала крайне мала и незначима.

2. У какого файла самая короткая длительность? Почему?

Самая короткая длительность у файла `speed_perturbed_speech_like.wav`. Скорее всего, длительность меньше потому, что для увеличения скорости число отсчетов сократил алгоритм пертурбации скорости.

3. Почему доля тишины может быть важна для ASR на длинных записях?

Доля тишины важна на длинных записях потому, что во-первых, при отсутствии алгоритма удаления тишины за обработку тишины приходится платить, во-вторых, тишина с точки зрения человека (отсутствие речевого сигнала) может быть заполнена шумом, который может распознаться как тихая речь, в-третьих, генеративные модели не обучены на том, чтобы генерировать тишину, поэтому они могут галлюцинировать на таких участках.

Часть С

Вопросы:

1. Какое искажение легче всего увидеть на волновой форме?

Мне кажется, легче всего увидеть клиппирование – горизонтальные полосы на самом верху.

2. Как выглядит клиппинг?

Клиппирование – это горизонтальные полосы в самом верху вейвформы – участки сигнала, амплитуда которых была выше, чем динамический диапазон микрофона.

3. Почему одной амплитуды может быть недостаточно, чтобы понять содержание речи?

Амплитуда показывает, насколько высок был уровень звукового давления на записывающее устройство или ухо человека, то есть, насколько громко было сказано что-то. Одной только громкости недостаточно для дешифровки сказанного.

Часть D

Вопросы:

1. В каком файле больше всего широкополосной высокочастотной энергии?

Больше всего широкополосной высокочастотной энергии в файл `noisy_speech_like.wav`: энергия шума присутствует на всех частотах во все моменты времени.

2. Как реверберация меняет time-frequency паттерн?

В реверберирующей записи на участках тишины присутствуют «повторения» речевого сигнала, сказанные ранее, это отражения звуковой волны от стен помещения, которые попали на микрофон после того, как диктор замолчал.

3. Почему шум может вызывать замены или удаления в ASR?

Шум может подмешиваться к участкам речевого сигнала и маскировать те из них, энергия которых мала (глухие согласные, слабо артикулированные окончания в русском языке), в результате, ASR может «не услышать» некоторые слова и не выдать их в транскрипции, либо сделать замену, когда часть слова была «услышана» правильно, а вторая часть либо не распознана вовсе, либо распознана неправильно.

Часть E

Вопросы:

1. Какую информацию легче увидеть на log-Mel, чем на волновой форме?

На log-Mel спектрограмме проще увидеть полосы частот с высокой энергией, на волновой форме их вообще не видно, так как глазом невозможно разобрать высокочастотные колебания и тем более, сравнивать колебания разных частот.

2. Какая информация теряется или сжимается по сравнению с линейно-частотной STFT?

При применении мел-шкалы теряется часть информации о высоких частотах, так как высокие частоты сжимаются из-за наложенных банков фильтров. Нельзя также определить точную частоту отдельной гармоник, так как видна только энергия в полосе. Также теряется информация о фазе сигнала, но эта информация не нужна для ASR.

3. Почему логарифмические энергии полезны для речи?

Логарифмические энергии полезны потому, что человеческий слух нелинеен, логарифмическая шкала лучше моделирует его особенности чем линейная. Кроме того, линейная шкала позволяет сократить размерность признаков за счет усреднения широких высокочастотных полос.

Часть F

Вопросы:

1. Чем визуально графики MFCC отличаются от log-Mel?

MFCC графики выглядят как «пикселизованные» графики log-Mel, они содержат низкочастотную информацию, так как изображают некоррелированные признаки. Этот формат более компактный и более общий: мало деталей, зато видно общую картину.

2. Почему компактное представление может быть полезным?

Компактное представление полезно для вычислений: они происходят быстрее. При этом компактность MFCC обусловлена не столько попыткой сэкономить ресурсы, сколько выделить действительно полезные признаки в сигнале, а именно, некоррелированные признаки, которые дают лучшее представление о речевом сигнале.

3. Почему современный нейросетевой ASR может предпочитать более богатые log-Mel признаки?

Современные системы ASR могут предпочитать log-Mel признаки потому, что, во-первых, на современном этапе нет смысла жестко экономить на размерности признаки, и чем более богатый речевой сигнал мы подаем в систему распознавания, тем, зачастую лучше. Во-вторых, современным нейросетям не нужно очень сильно «зачищать» сигнал, они обработают его сами, выделяя признаки, которые информативны.

Часть G

Искажение	Что изменилось в волновой форме?	Что изменилось в спектрограмме/log-Mel?	Возможный тип ошибки ASR
Шум	Участки пауз заполнены сигналом малой амплитуды. Огибающая речевого сигнала немного изменила форму.	Спектрограмма показывает наличие энергии во всех частотах: широкополосный шум присутствует на протяжении всей записи, речевой сигнал заметен не так явно, как без шума.	Вставки и замены, галлюцинации после пауз, плохое определение границ речи, из-за зашумления участков речи.
Реверберация	Огибающая речевого сигнала значительно изменила форму, высокочастотные колебания сгладились, появилось несколько сравнительно высоких пиков.	Фон спектрограммы стал более темным: широкополосный шум стал менее диффузным и «сложился» ближе к высокочастотным всплескам, паузы заполнились сигналом, повторяющим речевой с низкой энергией.	Вставки, неверные временные метки, галлюцинации после пауз, плохое определение границ речи, ухудшение пунктуации, так как речевой сигнал повторяется и заполняет паузы.
Клиппинг	Огибающая речевого сигнала неестественно квадратная.	Высокая энергия присутствует в широкой частотной полосе, паттерн речи при этом немного размытый.	Замены, галлюцинации после пауз из-за неестественного звучания речи на клиппированной записи.

Искажение	Что изменилось в волновой форме?	Что изменилось в спектрограмме/log-Mel?	Возможный тип ошибки ASR
Ускорение	Огибающая речевого сигнала не изменилась по форме, но отрезки речи стали уже.	Спектрограмма не изменилась, но участки речи стали уже	Мне кажется, возможны удаления и замены в связи с удалением некоторого количества отсчета и потерей информации о нечетких и коротких произнесениях

Подсказки по типам ошибок ASR:

- удаление;
- замена;
- вставка;
- неверная временная метка;
- плохое определение границ речи;
- галлюцинация после тишины/шума;
- ухудшение пунктуации/регистра в downstream-обработке.

Дополнительное задание

Речевой сигнал, записанный мной, выглядит иначе, чем синтезированные примеры. Волновая форма имеет нерегулярную огибающую, которая показывает колебание амплитуды во время речи и снижение амплитуды ближе к паузам. Спектрограмма характеризуется наличием широкополосного шума и менее явным паттерном речевого сигнала, который не похож на синусоиду, а похож на короткие отрезки в разных полосах частот.

