Отчет о лабораторной работе №2
Выполнила Е. Явшиц

1. **Выберите пару аугментаций, и проанализируйте, как они влияют на сигнал (поможет построить графики, подобные `clean_vs_augmented.png`). Какие два видимые изменения вы наблюдаете в волновой форме и/или log-Mel представлении?**

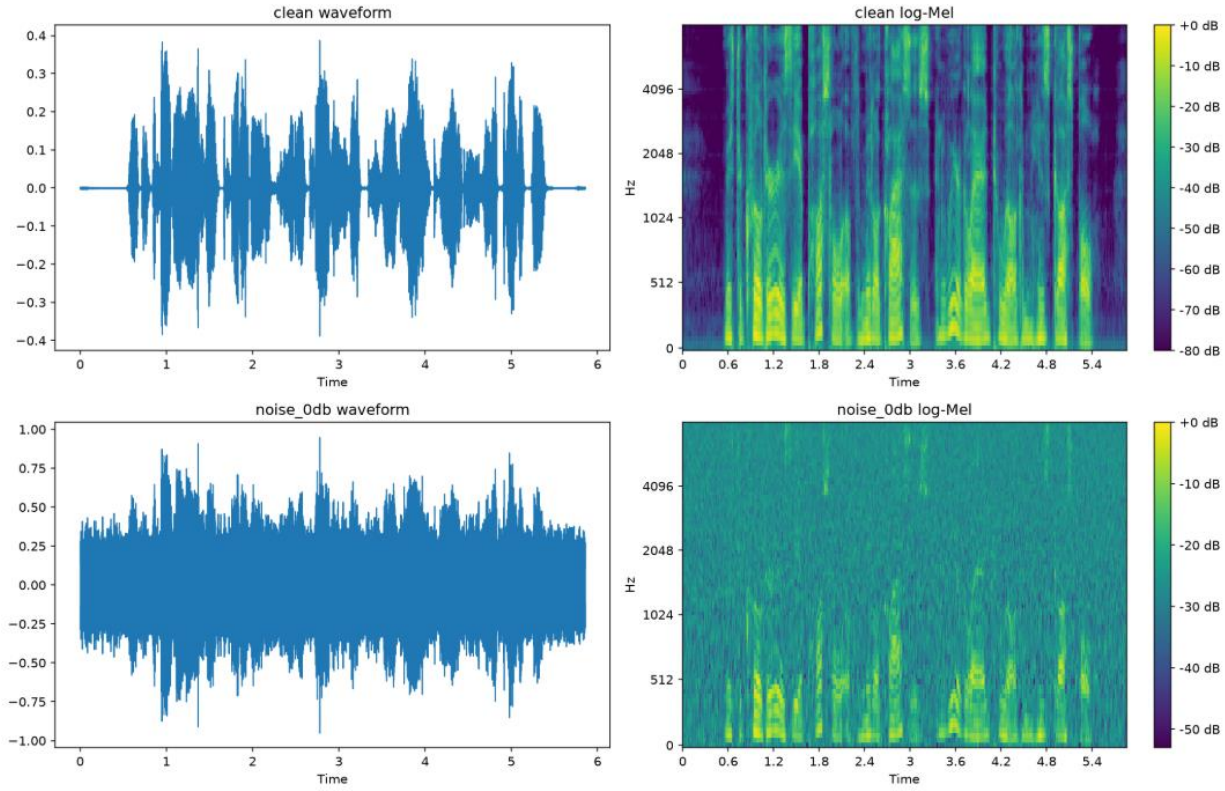


Рисунок 1 – Чистая и аугментированная шумом фонограмма

На рисунке 1 видно, что аугментированная шумом фонограмма выглядит иначе, чем до аугментации как на waveform, так и на лог-мел-спектрограмме. Шум, наложенный на фонограмму, заполнил участки тишины и значительно повлиял на участки речи с низкой амплитудой. В результате, волновая форма теперь имеет более высокую минимальную амплитуду, не демонстрирует паузы вообще. Лог-мел-спектрограмма теперь стала менее «контрастной», так как энергия каждого отсчета теперь значительно больше 0, в результате, спектрорамма выглядит смазанной, паттерны речи теряются в шуме: явно выделяются только фрагенты речи с наиболее высокой энергией. Данные графики показывают экстремальный случай, когда мощность и мощность сигнала равны. Если ОСШ более 0, то картина не такая яркая.

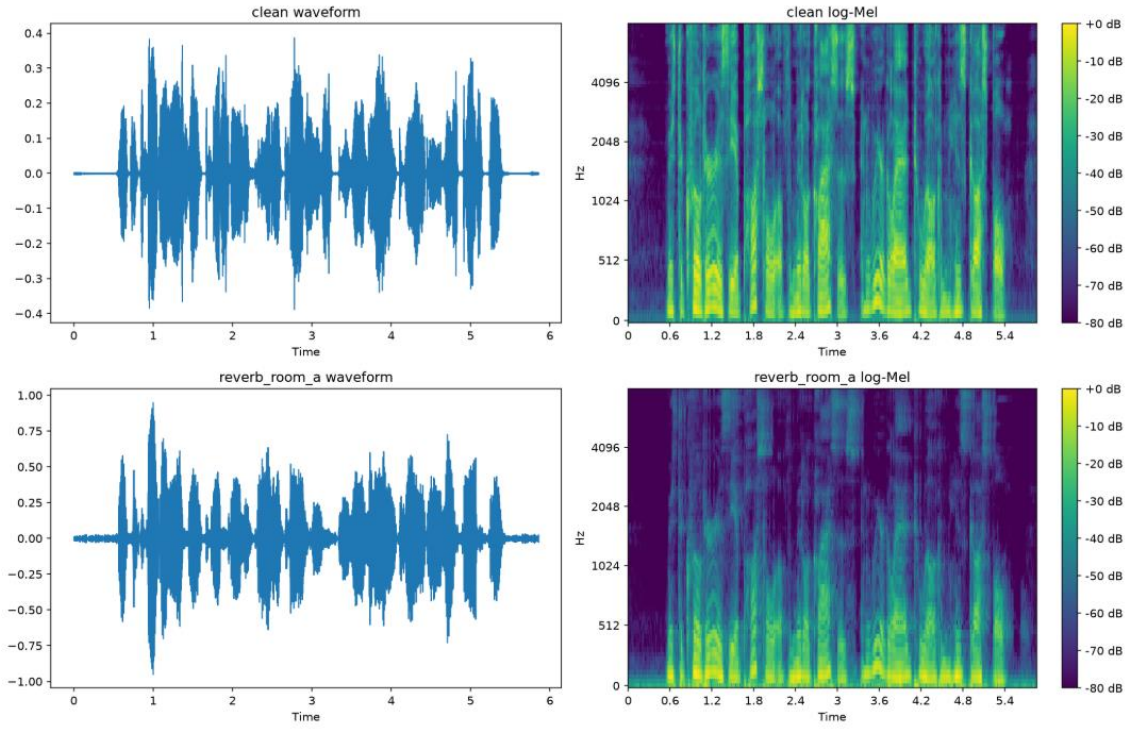


РИСУНОК 2 - ЧИСТАЯ И АУГМЕНТИРОВАННАЯ РЕВЕРБЕРАЦИЕЙ ФОНОГРАММА

На рисунке 2 реверберированная фонограмма значительно отличается от чистой как на графике волновой формы, так и на лог-мел-спектрограмме. На waveform заметно, что верхушки самых высоких пиков чистой фонограммы на графике аугментированной фонограммы, как будто обломаны и вставлены в моменты пауз: это отраженный звук, захваченный смоделированным устройством записи после отражения об стены помещения. На мел-спектрограмме энергия сигнала фрагментов речи стала заметно ниже, особенно в полосе высоких частот. Паузы стали менее явными из-за повышения энергии в них за счет отраженного звука. Также видно, что фрагменты речи смазались вправо: на спектрограмме аугментированного звука справа от сегмента речи появился туман.

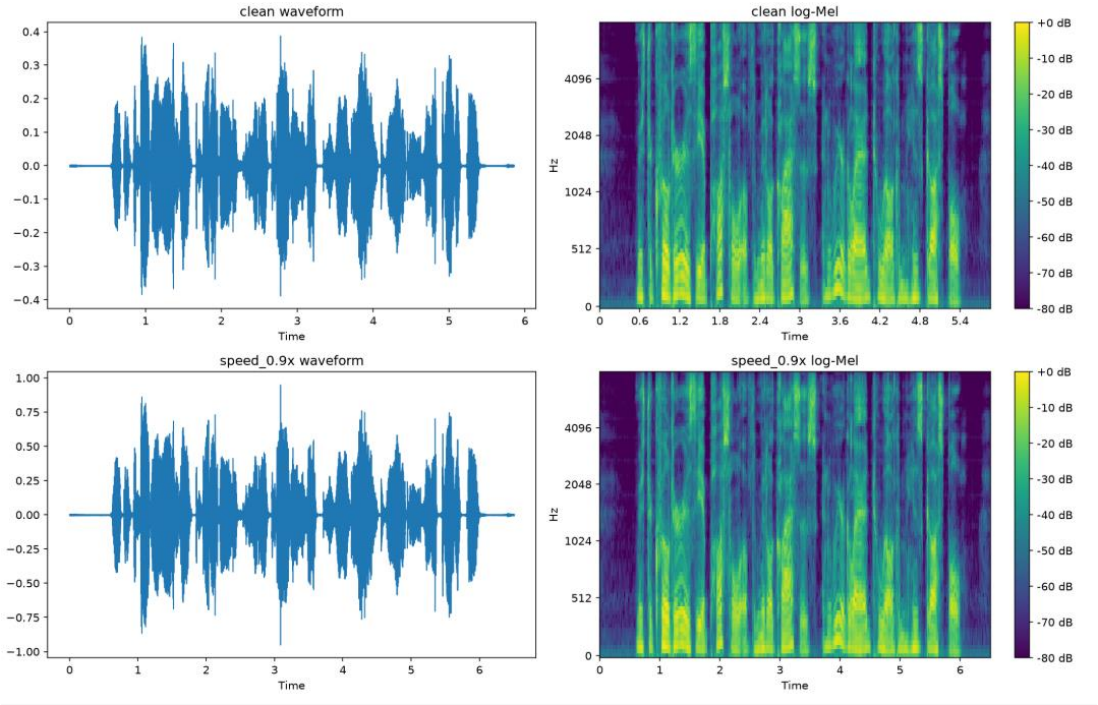


РИСУНОК 3 - ЧИСТАЯ И АУГМЕНТИРОВАННАЯ СКОРОСТЬЮ ФОНОГРАММА

В отличие от случаев, представленных на рисунке 1 и 2, фонограмма, аугментированная по скорости, визуально практически не отличается от чистой. Это и не удивительно, так как изменение скорости не приводит к искажению волновой формы или спектрограммы.

2. **Сравните аугментацию реверберацией `room_a` с аугментацией шумом (snr выберете сами). Какое видимое различие согласуется с временным размыванием, а не с простым аддитивным маскированием?**

Аугментация фонограммы шумом представляет собой аддитивное маскирование, так как шум добавляется к исходному речевому сигнала путем суммирования значений амплитуд для каждого отсчета. Это не предполагает искажение волновой формы или спектрограмы сигналы. Реверберация работает иначе и представляет собой временное размывание: часть звукового сигнала, отражаясь от стен помещения возвращается к устройству записи, превращая фрагменты речи на волновой форме в более «пухлые» фрагменты, то есть размытые на временной оси.

3. **Сравните длительности аудио 0.9× и 1.1× с исходыми. Как каждый фактор влияет на длительность и почему одного изменения длительности недостаточно для предсказания как себя поведёт WER?**

Рассмотрим результаты измерения WER и CER для 1272-128104-0000

Condition	audio_seconds	Изменение длины	WER	CER
clean	5.855	—	0.0588	0.0449

Condition	audio_seconds	Изменение длины	WER	CER
speed_0.9x	6.506	+11.1%	0.0588	0.0449
speed_1.1x	5.323	−9.1%	0.0588	0.0449

WER и CER вообще не изменились из-за изменения скорости. Скорее всего, это произошло потому, что выбранные множители для скорости меняют скорость речи не так уж значительно, и речевой сигнал остается вполне человеческим, таким, на котором, скорее всего, была обучена модель ASR. Изменения скорости на примерно 10% не искажают речевой сигнал так, как это могли бы сделать множители для скорости, равные 2 и более высоким целым числам. Так как при изменении скорости значения энергии сигнала в кадре остаются стабильными и пересчитываются через интерполяцию, спектрограмма не меняется и волновая форма, в целом, тоже. Незначительные корректировки скорости не приводят к повышению уровня ошибок распознавания, поэтому анализировать только скорость смысла нет, требуется учитывать временное смазывание (реверберацию) и аддитивный шум.

4. **Какие области скрыты временными и частотными масками в `specaugment_feature_only.png`? Предположите, почему такая аугментация может быть полезной для обучения систем ASR?**

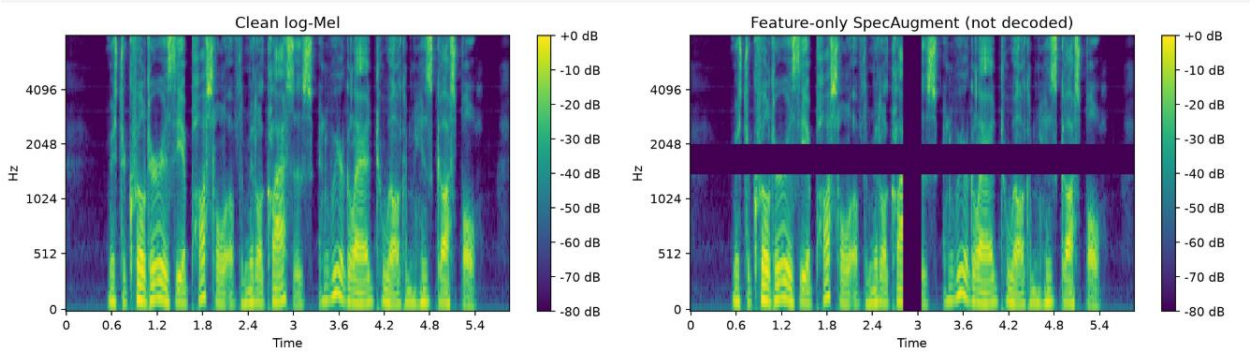


РИСУНОК 4 – СПЕКТРАЛЬНОЕ МАСКИРОВАНИЕ

На рисунке 5 замаскирована частотная полоса примерно от 1500 до 2000 Гц на протяжении всей записи, а также все частоты в районе 3-й секунды записи. Предполагаю, что такое маскирование делает систему ASR более робастной к снижению качества записи и позволяет лучше обобщать обучающие данные, не выучивая их.

5. **Для одного тестового примера сравните результаты распознавания чистого сигнала с результатами двух его аугментированных вариантов. Укажите WER, CER и RTF для всех трёх аудио. Какая метрика изменяется сильнее всего в выбранном сравнении? Как думаете, почему?**

Таблица для примера 1272-128104-0003:

Condition	WER	CER	RTF	Длительность (с)
clean	0.0417	0.0301	0.1112	9.9
reverb_room_a	0.1250	0.0526	0.1056	9.9
noise_0db	0.8333	0.5188	0.1106	9.9

Активнее всего меняется метрика WER, так как она достаточно строго штрафует за ошибки: любое изменение в слова считается ошибкой. CER меняется не так разительно. На изменение WER и CER сильнее всего повлияло зашумление (ОСШ = 0 дБ), причем на WER сильнее. RTF практически не изменился, так как эта метрика не реагирует на аугментацию данных, модель распознает все аудио в любом качестве так, как ей их дали.

6. **Определите вариант аугментации с наибольшим агрегированным `mean_wer` в `aggregate_results.csv`. Укажите его имя, агрегированные `mean_wer`, `mean_cer` и сравнение текстовок для одного тестового примера с этой аугментацией. Как вы думаете, почему такая аугментация сильнее всего сказывается на работе ASR модели?**

condition	mean_wer	mean_cer
noise_0db	**0.6445**	**0.3629**
noise_10db	0.1490	0.0818
reverb_room_a	0.1406	0.0704
noise_20db	0.1290	0.0715
speed_1.1x	0.0873	0.0541
clean	0.0840	0.0500
speed_0.9x	0.0840	0.0480

Пример 1272-128104-0003: WER для этого примера — 0.8333 (20 ошибок из 24 слов), CER — 0.5188.

Эталон:

he has grave doubts whether sir frederick leighton's work is really greek after all and can discover in it but little of rocky ithaca

Транскрибация при noise_0db:

he has great notes for that so he's going to make him work with me he's beat after all and he can discover in it a little while he isn't hurt

Зашумление очень высоким уровнем шума приводит к катастрофическому падению качества распознавания как по метрике WER, так и по метрике CER. Уровень шума, равный по мощности речевому сигнала приводит к тому, что сигнал грубо искажается и распознается очень плохо. Транскрибация вообще не соответствует сказанному. На рисунке 1 видно, как сильно аддитивный шум исказил речи, плавные переходы амплитуд от громкой речи к тишине пропали на волновой форме, на спектрограмме остались заметными только участки с самым высоким уровнем энергии.

7. **Найдите такой тип аугментации, для которого WER и CER сигнализируют о разном уровне влияния на систему ASR (скажем WER деградирует значительно, но CER увеличивается не очень сильно). Рассмотрите текстовки, предположите, почему наблюдается такое поведение?**

Рассмотрим 1272-128104-0003:

condition	WER	CER	Отношение WER/CER
clean	0.0417	0.0301	1.39
reverb_room_a	0.1250	0.0526	**2.38**
noise_10db	0.1667	0.0827	2.02
noise_20db	0.1667	0.0902	1.85
noise_0db	0.8333	0.5188	1.61

- **Эталон:** «he has grave doubts whether sir frederick leighton's work is really greek after all and can discover in it but little of rocky ithaca»
- **Транскрибация при** reverb_room_a**:** «he has grave doubts whether sir frederick **layton's** work is really greek after all and can discover in it but little of **wonky ithaka**»

3 ошибки в результате ASR.

Реверберация показывает самое сильное различие между WER и CER. WER реагирует даже на изменение 1 символа в слове, а CER – учитывает и правильные символы тоже.

Реверберация (в данном примере), в отличие от аддитивного шума при ОСШ 0 дБ, не портит звуковой сигнал настолько сильно, она не меняет его до неузнаваемости, поэтому у системы ASR есть шанс распознать сказанное близко к ручной разметке. Влияние реверберации особенно заметно по краям произнесений, но в целом, волновач форма не так искажена, как при наложении шума.

8. **Для идентичной ошибки/ошибок распознавания при разных типах аугментации приведите эталон и гипотезу (или их фрагменты). Является ли правдоподобным объяснением акустическое маскирование, временное размывание, сегментация/тайминг или предпочтение декодера/языковой модели? Укажите, какие у вас есть предположения, относительно таких ошибок распознавания.**

Для примера 1272-128104-0003

Condition	Фрагмент эталона	Фрагмент транскрибации
clean	...sir frederick **leighton's** work...	...sir frederick **layton's** work...
noise_20db	...sir frederick **leighton's** work...	...sir frederick **layton's** work...
noise_10db	...sir frederick **leighton's** work...	...sir frederick **leighton's** work...
reverb_room_a	...sir frederick **leighton's** work...	...sir frederick **layton's** work...
speed_0.9x	...sir frederick **leighton's** work...	...sir frederick **layton's** work...
speed_1.1x	...sir frederick **leighton's** work...	...sir frederick **layton's** work...

Мне кажется, ошибка в распознавании имени собственного связана только с bias языковой модели. Видимо, она предпочитает именно такой написание английской фамилии в ряде случаев, и ошибка не зависит от уровня шума.

9. Как вы думаете, всегда ли более высокий WER в нашем бенчмарке, есть индикатор того, что такая аугментация - универсальная ASR? Назовите два фактора в этой лабораторной работе, которые не позволяют сделать такой вывод.

1) В данной лабораторной работе мы делали аугментацию не для обучения модели (мы брали готовый инференс), а для искусственного расширения тестовых данных. Наша аугментация не может быть плохой, потому что она не участвовала в обучении, она просто показывает, к каким сигналам модель ASR не устойчива, в каких практических кейсах работать хорошо из коробки не будет.

2) У нас очень маленький тестовый корпус, мы не можем говорить о его универсальности, и примененные приемы аугментации тоже довольно ограниченные. Множителей для скорости у нас маловато, мало комнат, в которых сделала реверберация, шум только один. Нет разнообразия искажений, которое позволило бы нащупать со всех сторон границы применимости модели.